

Trabalho prático final - Parte 1 (T1)

Modelagem preditiva com Aprendizado de Máquina: Caracterização do problema e *spot-checking* de algoritmos

Contexto

Em Aprendizado de Máquina (AM), o *No-Free Lunch Theorem* estabelece que não há um único algoritmo com melhor desempenho universal, isto é, que seja o melhor algoritmo (e portanto, o recomendado) para todo e qualquer problema a ser resolvido. Assim, a recomendação ao se iniciar um novo projeto envolvendo o uso de algoritmos de aprendizado de máquina é explorar diferentes algoritmos em seu conjunto de dados para estabelecer um *baseline* de desempenho e escolher um subconjunto que parece ser mais promissor para justificar uma investigação mais aprofundada.

A ideia de rapidamente explorar diferentes métodos de aprendizado de máquina é normalmente referida como "*spot-checking algorithms*" (em tradução livre, verificação pontual de algoritmos): o principal objetivo é obter um conjunto inicial de informações sobre os algoritmos que potencialmente serão melhores para o desenvolvimento de modelos preditivos para um conjunto de dados, determinando em quais destes vale a pena dedicarmos mais tempo na otimização de hiperparâmetros e na análise mais aprofundada dos modelos. Portanto, *spot-checking* é diferente de realizar a otimização de um único algoritmo através do ajuste fino de seus hiperparâmetros. Podemos pensar no *spot-checking* como sendo uma primeira etapa na escolha de algoritmos, a qual irá refinar o conjunto de algoritmos a serem explorados em mais profundidade na etapa de otimização de hiperparâmetros.

Neste processo de *spot-checking*, é sempre recomendado testar um conjunto diversificado de algoritmos, com diferentes tipos de viés indutivo, variando, por exemplo:

- o tipo de representação de hipóteses (e.g., árvores e instâncias)
- a estratégia de aprendizado (e.g., probabilística ou por otimização)
- o tipo de modelagem (e.g., linear ou não linear, paramétrica ou não paramétrica)

Assim, o Trabalho Prático - Parte 1 (**T1**) da disciplina **INF01017** visa permitir que os alunos iniciem a modelagem de um problema preditivo de interesse e desenvolvam um

pipeline para fazer um *spot-checking* de algoritmos de aprendizado supervisionado para a tarefa selecionada, seja de classificação ou de regressão.

Objetivo do Trabalho

A proposta deste trabalho prático é que os alunos realizem a **caracterização de um problema de modelagem preditiva** (classificação ou regressão) e **implementem e executem um *spot-checking* de algoritmos** para a tarefa escolhida

Organizados em **grupos de 2 ou 3 pessoas**, os alunos devem selecionar um problema de interesse, coletar dados, realizar uma análise exploratória dos dados, realizar um pré-processamento inicial, e comparar um conjunto diversificado de algoritmos de aprendizado de máquina para resolvê-lo. Esta comparação será realizada de acordo com a proposta de *spot-checking* de fornecer de forma rápida e objetiva um primeiro conjunto de resultados em um novo problema de modelagem preditiva.

Em linhas gerais, o processo de spot-checking envolve:

- Carregar os dados
- Realizar um pré-processamento inicial dos dados (ex: normalização)
- Definir os algoritmos de aprendizado a serem aplicados
- Treinar e avaliar os modelos (utilizando valores padrões de hiperparâmetros ou variações mínimas)
- Sumarizar os resultados
- Apontar os algoritmos mais promissores

As seções a seguir detalham alguns aspectos relacionados ao desenvolvimento do trabalho.

Desenvolvimento

Definição do problema e coleta de dados

Pode ser utilizado qualquer conjunto de dados de interesse do grupo que esteja relacionado a uma tarefa de classificação ou regressão. Entretanto, sugere-se utilizar conjuntos de dados com baixa complexidade em termos de demandas de pré-processamento¹. Como sugestão para os alunos, alguns repositórios que podem ser buscados:

¹ Por baixa complexidade, entende-se conjuntos de dados que não demandam pré-processamento pesado, principalmente aspectos que ainda não foram tratados ao longo da disciplina, como imputação de dados, remoção de outliers, dentre outros. Tarefas de pré-processamento que podem ser facilmente abordadas pelos grupos são normalização e discretização de dados, e ajuste e balanceamento de classes.

PMLB : <https://epistasislab.github.io/pmlb/>

Kaggle: <https://www.kaggle.com/>

UCI ML Repository: <https://archive.ics.uci.edu/ml/datasets.php>

Solicita-se que, de preferência, os alunos utilizem conjuntos de dados que não foram explorados ao longo da disciplina (por exemplo, em atividades práticas). A tarefa a ser abordada deve estar bem descrita no relatório. Espera-se uma definição clara do objetivo do trabalho desenvolvido, ou seja, dos dados utilizados para treinamento dos modelos e da pergunta de pesquisa que o grupo visou investigar com algoritmos de AM. Por exemplo: "Nosso trabalho tem como objetivo desenvolver um modelo baseado em AM para prever o tipo de vinho (tinto ou branco) a partir de um conjunto de características físico-químicas. Para tanto, utilizamos o conjunto de dados <breve descrição> disponível em <link para download>." ...

Para os trabalhos que envolverem dados publicamente disponíveis, os grupos devem incluir o link para download no seu relatório.

Análise exploratória dos dados (EDA, de *Exploratory Data Analysis*)

Realize uma análise exploratória dos dados coletados². O objetivo é entender melhor e sumarizar as características dos dados, analisando quantidade e tipos de atributos, verificando distribuição do atributo alvo, identificando padrões e anomalias, removendo atributos que pareçam irrelevantes ou problemáticos, etc. Utilize gráficos e sumarizações estatísticas para a EDA. Verifique potenciais problemas nos dados, como por exemplo, a necessidade de normalizar os atributos, balancear classes, ou remover instâncias ou atributos por inconsistências nos dados. Inclua no seu relatório os resultados dessa análise e uma sumarização de eventuais problemas identificados.

Pré-processamento dos dados

Aplique técnicas de pré-processamento nos dados a fim de melhorar a qualidade dos mesmos por meio da eliminação ou minimização de problemas identificados na etapa anterior³. A avaliação deste trabalho não exigirá um pré-processamento aprofundado, por ser um tópico ainda pouco discutido na disciplina, mas será esperado que os grupos lidem com aspectos como a remoção de atributos ou instâncias problemáticas (por exemplo, por conterem muitos valores faltantes ou não parecerem informativas para o problema), normalização de atributos, balanceamento de classes,

² Leia o Capítulo 2 do livro base da disciplina "Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina", para referência.

³ Leia o Capítulo 3 do livro base da disciplina "Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina", para referência.

transformação de atributos de categórico para numérico, caso se mostrem necessários nos dados escolhidos.

As características dos dados usados, bem como as etapas envolvidas no pré-processamento dos dados, devem estar bem discutidas no relatório a ser entregue. Nos casos de não haver necessidade de pré-processar os dados, os grupos devem mencionar e justificar isto no texto.

Definição da abordagem, dos algoritmos, e da estratégia de avaliação

Defina a abordagem de aprendizado de máquina que você planeja utilizar, isto é, se o problema é de classificação ou regressão. Justifique sua escolha com base na natureza do problema e nos dados disponíveis.

Selecione os algoritmos de aprendizado supervisionado a serem aplicados. Esta definição é de livre escolha do grupo, mas solicita-se que englobe algoritmos que constem no conteúdo programático da disciplina (podendo incluir de forma adicional outros algoritmos não abordados na disciplina). Além disso, sugere-se selecionar um conjunto diversificado de algoritmos (em termos de viés indutivo), seguindo o propósito de spot-checking. Neste trabalho prático, os algoritmos podem ser aplicados como valores padrões de hiperparâmetros ou, se for a vontade do grupo, com uma variação mínima nos mesmos (como por exemplo, uma árvore de decisão sem poda e com uma poda não muito drástica). Os grupos devem comparar ao menos 5 algoritmos distintos.

Selecione as métricas de desempenho que serão usadas para avaliar os modelos a partir da definição da modelagem e da interpretação do problema a ser abordado. Neste processo, é recomendado utilizar mais de uma métrica para avaliação e comparação de modelos, mas selecionar uma métrica como critério principal de seleção de modelos (ou seja, aquela que o grupo tentará otimizar na análise de desempenho dos algoritmos). Escolha, também, a estratégia que aplicará para realizar a divisão de dados para treinamento e avaliação (holdout, cross-validation, etc..)

No relatório, descreva as suas decisões a respeito da abordagem, algoritmos e estratégias de avaliação empregados.

Spot-checking de algoritmos

Execute a verificação rápida dos algoritmos através do treinamento e avaliação dos modelos de acordo com as definições do item anterior. Testar uma variedade de algoritmos permite que se possa identificar quais modelos têm o melhor desempenho inicial com os dados disponíveis. Isso economiza tempo e esforço ao focar em algoritmos que realmente têm potencial.

Recomenda-se a execução de múltiplas repetições do treinamento e avaliação usando cada algoritmo selecionado. É importante garantir a consistência dos resultados

utilizando as mesmas divisões de dados em em uma determinada iteração para todos os algoritmos. Também é recomendado utilizar a definição manual de *seeds* em processos aleatórios (parâmetro *random_state*, no scikit-learn), para fins de reprodutibilidade dos experimentos. Lembre-se que neste trabalho prático não estamos interessados em realizar a otimização de hiperparâmetros ou a análise aprofundada dos modelos, como interpretabilidade dos mesmos.

Descreve no relatório a sua estratégia de spot-checking, incluindo detalhes sobre como lidou com a divisão de dados e se executou repetições do processo de treinamento e avaliação dos modelos.

Sumarização dos resultados

Faça a sumarização dos resultados da avaliação dos modelos. O objetivo desta sumarização é identificar quais algoritmos se saíram melhor e merecem seguir para uma investigação mais detalhada, fazendo uma escolha informada de algoritmos para otimização de modelos. *Atenção: esta investigação está fora do escopo do T1.*

Para esta etapa, sugere-se o uso de sumarização por média e desvio padrão do desempenho, bem como gráficos do tipo box plot, violin plot, joy plot, etc, para visualização da distribuição de desempenho por modelo ao longo de n execuções. O uso de gráficos é importante pois viabiliza uma análise visual dos resultados.

Os grupos devem analisar os resultados, discutir de forma comparativa o desempenho dos modelos, e apontar as 2-3 estratégias mais promissoras para o problema em questão. Inclua no seu relatório esta discussão, suportada por dados (gráficos, tabelas, dentre outros).

Entrega

Os grupos deverão enviar um arquivo **.zip** pelo moodle, contendo:

- O relatório em PDF, devidamente identificado e com um título significativo (de acordo com problema abordado). Este relatório deve ser dividido em quatro seções principais, com as descrições (e conclusões) relativas à:
 - (1) coleta de dados e identificação do problema;
 - (2) análise exploratória e pré-processamento dos dados;
 - (3) definição da abordagem, algoritmos e estratégias de avaliação;
 - (4) spot-checking de algoritmos;
- O código fonte usado no trabalho, incluindo todas as etapas envolvidas no desenvolvimento do projeto, do carregamento dos dados aos resultados do spot-checking.

- O código deve estar em um subdiretório 'src' dentro do arquivo .zip.
 - Python é a linguagem recomendada por conter bibliotecas importantes, como scikit-learn. Em especial, Jupyter Notebooks (e.g. Colab) são ótimas ferramentas de trabalho. Porém, o grupo pode implementar o código em qualquer linguagem de programação, mas deverão enviar o código com instruções simples e precisas, em um arquivo Readme.md, de como compilar (se necessário), e rodar o código. Caso o código tenha sido feito no Colab, baixe o .ipynb e envie no .zip. Não é válido o envio da URL do Colab.
 - Importante: caso a implementação seja no Colab, a simples exportação/impressão de um notebook como PDF não será aceito como relatório. O relatório deve ser um documento devidamente estruturado contendo as informações solicitadas acima.
- O relatório deve incluir referências a todas as fontes consultadas na execução do trabalho.
 - O trabalho prático deverá ser apresentado oralmente pelo grupo, durante o período de aula, em data a ser determinada pela professora. Esta apresentação será realizada ao final do semestre, após realização e entrega do T2. A nota da apresentação será embutida na avaliação do T2.
 - Prazo de entrega: 10/05/2026, às 23:59h, via Moodle
 - Deve ser feita **uma entrega por grupo**

Critérios de avaliação

- Pontualidade na entrega do trabalho.
 - *Atenção:* atrasos na entrega do trabalho serão penalizados proporcionalmente ao tempo de atraso, sendo descontado 1 (um) ponto por dia de atraso (o T1 como um todo vale 10 pontos).
- Completude do trabalho e atendimento aos requisitos definidos neste enunciado.
- Qualidade e correção da metodologia para desenvolvimento e verificação rápida dos modelos, incluindo todas as etapas previstas neste enunciado.
- Qualidade do relatório final e da apresentação e discussão dos resultados, e abrangência em relação aos requisitos de relato definidos neste enunciado.

Dúvidas

Em caso de dúvidas sobre a realização do trabalho, incluindo a definição do tema de pesquisa, entre em contato com a professora através do e-mail

mrmendoza@inf.ufrgs.br. Para dúvidas técnicas, sinta-se à vontade para usar o Fórum de Dúvidas no Moodle da disciplina.